Université d'Antananarivo

Faculté des Sciences

Mention Informatique et Technologie (MIT)

Grade : Master 1

Parcours : Innovation et Technologie (INT)

CLASSIFICATION HIÉRARCHIQUE ASCENDANTE ET MÉTHODE DES CENTRES MOBILES SOUS R

Étude des Habitudes de Vie Quotidienne

Nom :

RABESIHARISON Tolotraniaina Henri

9 juillet 2026

Année universitaire : 2025 – 2026

Sommaire

Avant-propos **1**

Introduction générale **2**

1 Généralités sur la classification automatique **4**

1.1 Objectifs de la classification 4

1.2 Notion de distance et de similarité 4

1.3 Les grandes familles de méthodes 5

1.3.1 Les méthodes hiérarchiques 5

1.3.2 Les méthodes de partitionnement 5

2 La Classification Ascendante Hiérarchique (CAH) **6**

2.1 Principe général de l'algorithme 6

2.2 Les critères d'agrégation 6

2.2.1 Le lien simple (single linkage) 6

2.2.2 Le lien complet (complete linkage) 6

2.2.3 Le lien moyen (average linkage) 7

2.2.4 Le critère de Ward 7

2.3 Le dendrogramme et le choix du nombre de classes 7

2.4 Avantages et limites de la CAH 7

3 La méthode des centres mobiles (k-means) **8**

3.1 Principe de l'algorithme 8

3.2 Étapes de l'algorithme 8

3.3 Choix du nombre de classes k 9

3.3.1 La méthode du coude (elbow method) 9

3.3.2 L'indice de silhouette 9

3.4 Avantages et limites 9

4 Approche mixte : CAH et centres mobiles **10**

4.1 Complémentarité des deux méthodes 10

4.2 Démarche de consolidation 10

5 Présentation des données **12**

5.1 Contexte et description du jeu de données 12

5.2 Prétraitement des données 12

6 Mise en œuvre de la CAH sous R **13**

6.1 Calcul de la matrice des distances 13

6.2 Construction du dendrogramme 13

6.3 Découpage de l'arbre 14

6.4 Interprétation des classes 14

7 Mise en œuvre des centres mobiles sous R **15**

7.1 Application de `kmeans()` 15

7.2 Détermination du nombre optimal de classes 15

7.3 Visualisation des classes 16

8 Consolidation et comparaison des résultats **17**

8.1 Croisement CAH / k-means 17

8.2 Profils des classes obtenues 17

8.3 Interprétation et recommandations 18

Conclusion générale **19**

Bibliographie **20**

Avant-propos

Ce document a été conçu comme un ouvrage pédagogique destiné à accompagner l'apprentissage des méthodes de classification automatique, et plus particulièrement de la Classification Ascendante Hiérarchique (CAH) et de la méthode des centres mobiles (k-means, également appelée méthode des nuées dynamiques). Il s'inscrit dans le prolongement des enseignements de statistique exploratoire multidimensionnelle dispensés en Master 1, parcours Innovation et Technologie, à la Mention Informatique et Technologie de la Faculté des Sciences de l'Université d'Antananarivo.

L'objectif poursuivi est double. D'une part, exposer de façon rigoureuse mais accessible les fondements théoriques de ces deux approches complémentaires de classification non supervisée. D'autre part, illustrer concrètement leur mise en œuvre à l'aide du logiciel R, à travers une étude appliquée portant sur les habitudes de vie quotidienne d'un échantillon d'individus.

La classification automatique occupe une place centrale dans l'analyse de données modernes : segmentation de clientèle, typologie de comportements, structuration de grands volumes d'informations, aide à la décision. Comprendre la logique, les forces et les limites de la CAH et des centres mobiles constitue ainsi un socle indispensable pour tout praticien de la donnée.

Introduction générale

Dans de nombreux domaines — marketing, sociologie, biologie, économie, sciences de l'ingénieur — l'analyste est confronté à des jeux de données comportant un grand nombre d'individus décrits par plusieurs variables. Une question récurrente se pose alors : existe-t-il, au sein de cette population, des groupes homogènes d'individus qui se ressemblent entre eux et se distinguent des autres groupes ? Répondre à cette question relève de la classification automatique, également appelée analyse typologique ou *clustering*.

Contrairement aux méthodes supervisées, la classification automatique ne suppose aucune connaissance préalable de l'appartenance des individus à des groupes : c'est la structure même des données qui doit révéler une typologie pertinente. Deux grandes familles de méthodes se distinguent historiquement pour répondre à ce problème : les méthodes hiérarchiques, dont la Classification Ascendante Hiérarchique (CAH) est la plus emblématique, et les méthodes de partitionnement, dont la méthode des centres mobiles est la référence.

La CAH construit progressivement, par agrégations successives des individus ou groupes d'individus les plus proches, une hiérarchie de partitions représentée sous la forme d'un arbre appelé *dendrogramme*. La méthode des centres mobiles, quant à elle, procède par réallocations itératives des individus autour de centres de gravité (centroïdes) recalculés à chaque étape, jusqu'à convergence vers une partition stable en un nombre de classes k fixé a priori.

Ces deux approches, loin d'être concurrentes, sont en réalité complémentaires : la pratique statistique recommande fréquemment de les combiner, en utilisant par exemple la CAH pour déterminer un nombre de classes pertinent et initialiser les centres, puis la méthode des centres mobiles pour consolider la partition obtenue. Cette démarche mixte, dite de « consolidation », permet de tirer parti à la fois de la richesse interprétative du dendrogramme et de la robustesse numérique de l'algorithme itératif des centres mobiles.

Le présent ouvrage se structure en deux grandes parties. La première partie pose le cadre théorique : notions de distance et de similarité, principes de la CAH, principes de la méthode des centres mobiles, et démarche de consolidation. La seconde partie propose une application complète sous le logiciel R, à partir d'un jeu de données portant sur les habitudes de vie quotidienne (activité physique, sommeil, alimentation, temps d'écran, etc.) d'un ensemble d'individus, permettant d'illustrer pas à pas l'ensemble de la démarche, du prétraitement des données jusqu'à l'interprétation des classes obtenues.

PARTIE I

CADRE THÉORIQUE DE LA CLASSIFICATION AUTOMATIQUE

Chapitre 1

Généralités sur la classification automatique

1.1 Objectifs de la classification

La classification automatique, ou *clustering*, a pour objectif de répartir un ensemble d'individus décrits par plusieurs variables en un nombre restreint de groupes, appelés classes ou clusters, de telle sorte que :

- les individus appartenant à une même classe soient le plus homogènes possible (forte ressemblance intra-classe) ;
- les classes soient le plus distinctes possible les unes des autres (forte hétérogénéité inter-classes).

Cette double exigence d'homogénéité intra-classe et de séparation inter-classes constitue le fil conducteur de toutes les méthodes de classification, qu'elles soient hiérarchiques ou de partitionnement.

1.2 Notion de distance et de similarité

Toute méthode de classification repose sur la définition d'une mesure de proximité entre individus. Lorsque les variables sont quantitatives, la distance euclidienne est la plus couramment utilisée :

$$d(i, j) = \sqrt{\sum_{k=1}^{p} (x_{ik} - x_{jk})^2}$$

où x_{ik} désigne la valeur de la variable k pour l'individu i, et p le nombre total de variables.

D'autres distances existent selon la nature des données : distance de Manhattan (somme des écarts absolus), distance de Minkowski (généralisation paramétrée), distance du Chi-deux (pour des données de comptage), ou encore des indices de similarité adaptés aux variables qualitatives (indice de Jaccard, de Dice, etc.).

▶ À retenir

Lorsque les variables sont exprimées dans des unités différentes (par exemple des heures de sommeil et un nombre de pas quotidiens), une variable à forte variance peut dominer artificiellement le calcul des distances. Il est donc indispensable de procéder à un **centrage-réduction** des variables (standardisation) avant tout calcul de distance.

1.3 Les grandes familles de méthodes

On distingue traditionnellement deux grandes familles de méthodes de classification automatique.

1.3.1 Les méthodes hiérarchiques

Elles produisent une hiérarchie complète de partitions emboîtées, depuis la partition où chaque individu forme sa propre classe jusqu'à la partition regroupant tous les individus en une seule classe. Cette hiérarchie est représentée graphiquement par un dendrogramme. La Classification Ascendante Hiérarchique (CAH), procédant par agrégations successives, en est l'illustration la plus répandue ; il existe aussi une variante descendante (*divisive*), beaucoup moins utilisée en pratique.

1.3.2 Les méthodes de partitionnement

Elles cherchent directement une partition en un nombre k de classes fixé a priori, en optimisant un critère numérique (le plus souvent la minimisation de l'inertie intra-classe). La méthode des centres mobiles (*k-means*) est la représentante la plus connue de cette famille. Contrairement à la CAH, elle ne fournit pas de hiérarchie mais une unique partition, obtenue par un processus itératif.

Critère	CAH (hiérarchique)	Centres mobiles (k-means)
Résultat produit	Hiérarchie complète (dendrogramme)	Une seule partition en k classes
Nombre de classes	Choisi a posteriori (coupure de l'arbre)	Fixé a priori
Complexité	$O(n^2 \log n)$ à $O(n^3)$	$O(n \cdot k \cdot i)$, très rapide
Grands effectifs	Non (coûteuse en mémoire)	Oui
Stabilité du résultat	Déterministe	Dépend de l'initialisation
Lecture visuelle	Dendrogramme très lisible	Nuage de points / projection

Tableau 1.1: Comparaison synthétique des deux grandes familles de méthodes

Chapitre 2

La Classification Ascendante Hiérarchique (CAH)

2.1 Principe général de l'algorithme

La CAH est une procédure itérative qui part de la partition la plus fine possible, dans laquelle chaque individu constitue à lui seul une classe, puis regroupe à chaque étape les deux classes les plus proches, jusqu'à n'obtenir plus qu'une seule classe regroupant l'ensemble des individus. L'algorithme se résume ainsi :

1. Initialiser n classes, chacune réduite à un individu.
2. Calculer la matrice des distances entre toutes les paires de classes.
3. Fusionner les deux classes les plus proches selon un critère d'agrégation choisi.
4. Mettre à jour la matrice des distances en tenant compte de la nouvelle classe formée.
5. Répéter les étapes 3 et 4 jusqu'à ce qu'il ne reste qu'une seule classe.

Chaque fusion est enregistrée avec la distance à laquelle elle s'est produite, ce qui permet de construire le **dendrogramme**, arbre binaire retraçant l'historique complet des regroupements.

2.2 Les critères d'agrégation

La distance entre deux classes (et non plus entre deux individus) doit être définie à chaque étape de l'algorithme. Le choix du critère d'agrégation influence fortement la forme des classes obtenues.

2.2.1 Le lien simple (single linkage)

La distance entre deux classes est définie comme la plus petite distance entre un individu de la première classe et un individu de la seconde. Ce critère tend à produire des classes allongées (effet de chaîne) et est sensible aux valeurs atypiques.

2.2.2 Le lien complet (complete linkage)

La distance entre deux classes est définie comme la plus grande distance entre un individu de la première classe et un individu de la seconde. Ce critère favorise des classes compactes et de

diamètre limité.

2.2.3 Le lien moyen (average linkage)

La distance entre deux classes est la moyenne de toutes les distances entre individus des deux classes. Ce critère constitue un compromis entre les deux précédents.

2.2.4 Le critère de Ward

Très utilisé en pratique, le critère de Ward ne repose plus directement sur une distance entre individus mais sur une perte d'inertie : à chaque étape, on fusionne les deux classes dont le regroupement entraîne la plus faible augmentation de l'inertie intra-classe totale.

▶ À retenir

Le critère de **Ward** produit généralement des classes de tailles équilibrées et bien contrastées, ce qui en fait le choix par défaut recommandé dans la plupart des études appliquées.

2.3 Le dendrogramme et le choix du nombre de classes

Le dendrogramme est une représentation graphique en forme d'arbre, où l'axe vertical indique la distance (ou l'inertie) à laquelle chaque fusion a eu lieu. Plus une branche est haute, plus la fusion correspondante rapproche des classes dissemblables.

Le choix du nombre de classes à retenir s'effectue généralement en repérant, sur le dendrogramme, le plus grand saut entre deux niveaux de fusion consécutifs : ce saut signale le passage d'un regroupement de classes proches à un regroupement de classes nettement plus éloignées, et constitue donc un bon indicateur du niveau de coupure à privilégier. On parle de règle du « saut d'inertie » ou de perte relative d'inertie.

2.4 Avantages et limites de la CAH

Avantages	Limites
Fournit une hiérarchie complète, exploitable à tout niveau de finesse	Coût de calcul élevé, peu adaptée aux grands volumes de données
Le dendrogramme offre une lecture visuelle riche de la structure des données	Une fusion est définitive : impossible de revenir sur une agrégation erronée
Aucun choix a priori du nombre de classes	Sensibilité au critère d'agrégation choisi et aux valeurs atypiques
Déterministe : un même jeu de données donne toujours le même résultat	Difficile à interpréter au-delà de quelques centaines d'individus

Tableau 2.1: Avantages et limites de la CAH

Chapitre 3

La méthode des centres mobiles (k-means)

3.1 Principe de l'algorithme

La méthode des centres mobiles, popularisée sous le nom de *k-means*, appartient à la famille des méthodes de partitionnement. Elle vise à répartir les n individus en un nombre k de classes fixé à l'avance, de manière à minimiser l'inertie intra-classe totale, c'est-à-dire la somme des carrés des distances entre chaque individu et le centre de gravité (centroïde) de sa classe :

$$W = \sum_{c=1}^{k} \sum_{i \in c} d(i, g_c)^2$$

où g_c désigne le centre de gravité de la classe c.

Le nom « nuées dynamiques », proposé par Edwin Diday, souligne le caractère mouvant des centres de classes au fil des itérations : chaque centre se déplace progressivement vers le barycentre des individus qui lui sont affectés, jusqu'à stabilisation.

3.2 Étapes de l'algorithme

1. Choisir k, le nombre de classes souhaité.
2. Sélectionner aléatoirement k individus (ou points) comme centres initiaux des classes.
3. Affecter chaque individu à la classe dont le centre est le plus proche (selon la distance euclidienne).
4. Recalculer le centre de chaque classe comme le barycentre (moyenne) des individus qui lui sont désormais affectés.
5. Répéter les étapes 3 et 4 jusqu'à ce que les affectations ne changent plus (convergence) ou qu'un nombre maximal d'itérations soit atteint.

▶ À retenir

Cet algorithme converge toujours vers un optimum **local** en un nombre fini d'itérations, mais rien ne garantit qu'il s'agisse de l'optimum global : le résultat final dépend du choix des centres initiaux. En pratique, on relance l'algorithme plusieurs fois à partir d'initialisations différentes et l'on conserve la partition minimisant l'inertie intra-classe totale (paramètre `nstart` sous R).

3.3 Choix du nombre de classes k

Contrairement à la CAH, la méthode des centres mobiles exige que le nombre k soit fixé avant l'exécution de l'algorithme. Deux approches complémentaires permettent de guider ce choix.

3.3.1 La méthode du coude (elbow method)

On exécute l'algorithme pour des valeurs croissantes de k et on trace l'évolution de l'inertie intra-classe totale en fonction de k. Cette courbe décroît naturellement lorsque k augmente ; on retient la valeur de k au-delà de laquelle le gain d'inertie devient marginal, ce qui se traduit graphiquement par un « coude » sur la courbe.

3.3.2 L'indice de silhouette

Pour chaque individu, l'indice de silhouette compare la distance moyenne à son propre groupe et la distance moyenne au groupe voisin le plus proche. Il varie entre -1 et 1 : une valeur proche de 1 indique un individu bien classé, une valeur proche de 0 indique une position ambiguë entre deux classes, une valeur négative suggère un individu probablement mal classé.

3.4 Avantages et limites

Avantages	Limites
Très rapide, adaptée aux grands jeux de données	Le nombre de classes k doit être fixé a priori
Simple à mettre en œuvre et à interpréter	Résultat sensible à l'initialisation des centres
Peut être relancée facilement (`nstart`)	Suppose des classes de forme globalement sphérique
Fonctionne bien sur variables quantitatives standardisées	Sensible aux valeurs atypiques (outliers)

Tableau 3.1: Avantages et limites de la méthode des centres mobiles

Chapitre 4

Approche mixte : CAH et centres mobiles

4.1 Complémentarité des deux méthodes

La CAH et la méthode des centres mobiles présentent des qualités et des défauts largement complémentaires. La CAH offre une vision hiérarchique riche mais devient rapidement coûteuse en temps de calcul et en mémoire lorsque le nombre d'individus augmente. La méthode des centres mobiles est rapide et efficace sur de grands effectifs, mais nécessite de connaître à l'avance le nombre de classes et reste sensible à l'initialisation.

La pratique statistique a donc développé une démarche dite de « consolidation », qui combine les deux méthodes afin de cumuler leurs avantages respectifs tout en limitant leurs inconvénients.

4.2 Démarche de consolidation

La démarche de consolidation se déroule typiquement en trois temps :

1. Une première classification par la méthode des centres mobiles est réalisée sur un nombre de classes volontairement élevé (par exemple une cinquantaine de micro-classes), afin de réduire le volume de données tout en préservant la structure fine du nuage de points.
2. Une CAH est ensuite appliquée, non plus sur les individus bruts, mais sur les centres de gravité de ces micro-classes, pondérés par leurs effectifs respectifs. Le dendrogramme obtenu permet de déterminer un nombre de classes final pertinent.
3. Les centres de classes issus de la coupure du dendrogramme servent enfin de centres initiaux à une nouvelle exécution de l'algorithme des centres mobiles, appliquée cette fois sur l'ensemble des individus d'origine, afin de consolider et d'affiner la partition finale.

Cette démarche, popularisée notamment par les travaux de l'école française d'analyse des données, permet de traiter efficacement de grands jeux de données tout en bénéficiant de la lisibilité interprétative offerte par le dendrogramme. Dans le cadre de la présente étude, dont l'effectif reste modéré, la CAH sera appliquée directement pour déterminer le nombre de classes pertinent, puis la méthode des centres mobiles sera utilisée pour consolider la partition, illustrant ainsi une version simplifiée de cette démarche mixte.

PARTIE II

APPLICATION SOUS R : ÉTUDE DES HABITUDES DE VIE QUOTIDIENNE

Chapitre 5

Présentation des données

5.1 Contexte et description du jeu de données

L'étude proposée porte sur un ensemble d'individus décrits par plusieurs variables quantitatives relatives à leurs habitudes de vie quotidienne : durée moyenne de sommeil (en heures), temps quotidien d'activité physique (en minutes), temps quotidien passé devant un écran (en heures), nombre de repas équilibrés par semaine, quantité d'eau consommée par jour (en litres), et niveau de stress auto-évalué (échelle de 1 à 10). L'objectif est d'identifier, à partir de ces variables, des profils-types d'individus aux modes de vie homogènes.

5.2 Prétraitement des données

Les variables retenues étant exprimées dans des unités et des échelles hétérogènes, une étape de centrage-réduction est indispensable avant tout calcul de distance, afin d'éviter qu'une variable à forte variance (par exemple le temps d'écran, exprimé en dizaines de minutes) ne domine artificiellement la classification au détriment d'une variable à faible variance (par exemple le nombre de repas équilibrés). Sous R, cette standardisation s'effectue simplement à l'aide de la fonction `scale()`.

```
# Importation et preparation des donnees
data <- read.csv2("habitudes_vie.csv", row.names = 1)
str(data)
summary(data)

# Centrage-reduction des variables quantitatives
data_cr <- scale(data)
head(round(data_cr, 2))
```

Script R 5.1 — Importation et standardisation des données

Chapitre 6

Mise en œuvre de la CAH sous R

6.1 Calcul de la matrice des distances

La première étape consiste à calculer la matrice des distances euclidiennes entre individus, à partir des données standardisées, à l'aide de la fonction `dist()`.

```
# Matrice des distances euclidiennes
d <- dist(data_cr, method = "euclidean")
```

6.2 Construction du dendrogramme

La fonction `hclust()` applique ensuite l'algorithme de Classification Ascendante Hiérarchique à partir de cette matrice de distances. Le critère de Ward (`method = "ward.D2"`) est retenu, conformément aux recommandations usuelles pour obtenir des classes équilibrées et bien contrastées.

```
# Classification Ascendante Hierarchique - critere de Ward
cah <- hclust(d, method = "ward.D2")

# Representation graphique du dendrogramme
plot(cah, main = "Dendrogramme - CAH (critere de Ward)",
xlab = "Individus", ylab = "Hauteur (inertie)", cex = 0.6)

# Visualisation des sauts d'inertie pour guider la coupure
inertie <- sort(cah$height, decreasing = TRUE)
plot(inertie[1:10], type = "b", pch = 19,
xlab = "Nombre de classes", ylab = "Inertie",
main = "Eboulis des inerties")
```

Script R 6.1 — Construction du dendrogramme et repérage du saut d'inertie

L'observation de l'éboulis des inerties (analogue au « scree plot » de l'ACP) permet de repérer le saut le plus marqué entre deux niveaux de fusion successifs, indiquant ici une coupure pertinente en quatre classes.

6.3 Découpage de l'arbre

Une fois le nombre de classes déterminé, la fonction `cutree()` permet d'obtenir directement le vecteur d'appartenance de chaque individu à sa classe.

```r
# Decoupage du dendrogramme en 4 classes
classes_cah <- cutree(cah, k = 4)
table(classes_cah)

# Mise en couleur du dendrogramme selon les classes retenues
library(dendextend)
dend <- as.dendrogram(cah)
dend_colore <- color_branches(dend, k = 4)
plot(dend_colore, main = "Dendrogramme - 4 classes")
rect.hclust(cah, k = 4, border = 2:5)
```

Script R 6.2 — Découpage en classes et mise en évidence sur le dendrogramme

6.4 Interprétation des classes

L'interprétation des classes issues de la CAH s'appuie sur le calcul des moyennes de chaque variable au sein de chaque classe, comparées à la moyenne générale de l'échantillon. Cette description permet de caractériser chaque groupe par un profil-type : par exemple, une classe pourra rassembler des individus présentant une durée de sommeil élevée, un temps d'écran réduit et un niveau de stress faible, traduisant un mode de vie globalement équilibré, tandis qu'une autre classe pourra regrouper des individus au profil inverse.

```r
# Profil moyen de chaque classe
aggregate(data, by = list(classe = classes_cah), FUN = mean)
```

Chapitre 7

Mise en œuvre des centres mobiles sous R

7.1 Application de `kmeans()`

La fonction `kmeans()` implémente sous R l'algorithme des centres mobiles. Le nombre de classes $k = 4$, déterminé au chapitre précédent à partir du dendrogramme, est repris ici afin de permettre une comparaison directe des deux méthodes. Le paramètre `nstart` permet de relancer l'algorithme plusieurs fois à partir d'initialisations différentes et de conserver la meilleure solution.

```r
# Methode des centres mobiles (k-means), k = 4
set.seed(123)
km <- kmeans(data_cr, centers = 4, nstart = 25)
km$size           # effectif de chaque classe
km$centers        # coordonnees des centres (donnees standardisees)
km$tot.withinss   # inertie intra-classe totale
```

Script R 7.1 — Application de l'algorithme des centres mobiles

7.2 Détermination du nombre optimal de classes

Afin de vérifier la pertinence du choix $k = 4$, la méthode du coude et l'indice de silhouette sont mobilisés conjointement.

```r
# Methode du coude
inertie_intra <- sapply(1:10, function(k) {
  kmeans(data_cr, centers = k, nstart = 25)$tot.withinss
})
plot(1:10, inertie_intra, type = "b", pch = 19,
xlab = "Nombre de classes k", ylab = "Inertie intra-classe",
main = "Methode du coude")

# Indice de silhouette
library(cluster)
library(factoextra)
fviz_nbclust(data_cr, kmeans, method = "silhouette")
```

Script R 7.2 — Méthode du coude et indice de silhouette

7.3 Visualisation des classes

Le package `factoextra` offre une fonction `fviz_cluster()` particulièrement pratique pour visualiser les classes obtenues par k-means, en projetant les individus sur les deux premiers axes d'une analyse en composantes principales lorsque le nombre de variables initiales dépasse deux.

```
# Visualisation des classes sur le premier plan factoriel
fviz_cluster(km, data = data_cr,
geom = "point", ellipse.type = "convex",
palette = "jco", ggtheme = theme_minimal(),
main = "Classification par centres mobiles (k = 4)")
```

Script R 7.3 — Visualisation des classes k-means

Chapitre 8

Consolidation et comparaison des résultats

8.1 Croisement CAH / k-means

Une étape essentielle de validation consiste à comparer les partitions obtenues respectivement par la CAH et par la méthode des centres mobiles, à l'aide d'un tableau croisé. Une forte concordance entre les deux partitions renforce la confiance dans la typologie obtenue.

```r
# Tableau de comparaison des deux partitions
table(CAH = classes_cah, KMEANS = km$cluster)

# Indice de concordance (Rand ajuste)
library(mclust)
adjustedRandIndex(classes_cah, km$cluster)
```

Script R 8.1 — Comparaison des partitions CAH et k-means

▶ À retenir

Un indice de Rand ajusté proche de 1 traduit une forte concordance entre les deux méthodes, confirmant la stabilité et la robustesse de la typologie en quatre classes retenue pour cette étude.

8.2 Profils des classes obtenues

La consolidation finale des classes, réalisée en utilisant les centres issus de la CAH comme points de départ de l'algorithme des centres mobiles, permet d'aboutir à une typologie stabilisée des individus selon leurs habitudes de vie quotidienne. Quatre profils-types se dégagent généralement de ce type d'étude :

- **Classe 1** — **« Mode de vie équilibré »** : sommeil suffisant, activité physique régulière, temps d'écran modéré, stress faible.
- **Classe 2** — **« Sédentaires connectés »** : temps d'écran élevé, activité physique faible, sommeil de qualité moyenne.
- **Classe 3** — **« Actifs sous tension »** : activité physique élevée mais niveau de stress

également élevé et sommeil réduit.

- **Classe 4 — « Vie irrégulière »** : alimentation peu structurée, hydratation insuffisante, sommeil très variable.

Ces profils, purement illustratifs, doivent bien entendu être validés et affinés au regard des résultats effectivement obtenus sur le jeu de données réel étudié.

8.3 Interprétation et recommandations

Au-delà de la seule description statistique, l'intérêt d'une telle typologie réside dans son exploitation pratique : orientation de campagnes de sensibilisation à la santé publique ciblées par profil, adaptation de programmes d'accompagnement individualisés, ou encore identification de leviers d'action prioritaires selon le groupe considéré. La combinaison de la CAH et de la méthode des centres mobiles, en offrant à la fois une lecture hiérarchique et une partition consolidée robuste, constitue ainsi un outil précieux d'aide à la décision fondé sur les données.

Conclusion générale

Ce livre a présenté, de façon progressive, les fondements théoriques et la mise en œuvre pratique de deux méthodes complémentaires de classification automatique : la Classification Ascendante Hiérarchique et la méthode des centres mobiles. La première offre une vision hiérarchique riche, matérialisée par le dendrogramme, permettant d'explorer la structure des données à différents niveaux de finesse. La seconde, plus rapide et mieux adaptée aux grands effectifs, permet d'obtenir directement une partition consolidée en un nombre de classes fixé.

L'application conduite sur un jeu de données relatif aux habitudes de vie quotidienne a permis d'illustrer concrètement l'ensemble de la démarche sous R : préparation et standardisation des données, construction et lecture du dendrogramme, choix du nombre de classes, exécution de l'algorithme des centres mobiles, validation croisée des deux partitions, et enfin interprétation des profils-types obtenus.

Cette étude confirme l'intérêt d'une démarche mixte, combinant les atouts respectifs de la CAH et des centres mobiles, pour obtenir une typologie à la fois interprétable et statistiquement robuste. Elle ouvre également la voie à des approfondissements possibles : intégration de variables qualitatives supplémentaires, comparaison avec d'autres méthodes de classification (classification par densité, mélanges gaussiens), ou encore couplage avec une analyse factorielle préalable (ACP) afin de résumer l'information avant classification, notamment lorsque le nombre de variables initiales est important.

Bibliographie

Ward J.H. (1963). *Hierarchical Grouping to Optimize an Objective Function.* Journal of the American Statistical Association.

MacQueen J. (1967). *Some Methods for Classification and Analysis of Multivariate Observations.* Proceedings of the Fifth Berkeley Symposium.

Diday E. (1971). *La méthode des nuées dynamiques.* Revue de statistique appliquée.

Lebart L., Piron M., Morineau A. (2006). *Statistique exploratoire multidimensionnelle.* Dunod.

Husson F., Lê S., Pagès J. (2016). *Analyse de données avec R.* Presses Universitaires de Rennes.

Kaufman L., Rousseeuw P.J. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis.* Wiley.

Documentation officielle des packages R : `stats`, `cluster`, `factoextra`, `dendextend`, `mclust`.